News Viral Lens 新聞熱度預測系統——基於 NLP 與 AI 驅動的媒體決策輔助系統

團隊名稱： NEWS HUNTER 團隊成員： 李明哲（隊長）、何立淳

一、 專案背景與痛點分析

在當前的數位環境中，我們觀察到從流量焦慮到資訊守門的挑戰：

1. **資訊過載與流量焦慮 (Information Overload)：** 隨著生成式 AI (GenAI) 讓內容生產成本降低，新聞與資訊的產出量呈指數級爆炸，媒體與平台面臨前所未有的「內容海嘯」。
2. **流量預測的盲點：** 傳統編輯台在選題與推播時，往往依賴「經驗」或「直覺」進行盲賭，缺乏科學化的指標來預判哪則新聞會爆紅。
3. **速度的競賽 (The Need for Speed)：** 一篇新聞從發布到爆紅 (Viral) 往往只有極短的黃金窗口。
    - **對媒體而言：** 若無法在初期識別潛力股，將錯失流量紅利。
    - **對社會而言：** 若是惡意資訊爆紅，查核中心往往在擴散後才介入，此時傷害已經造成——真相跑得比謠言慢 6 倍。

二、 專案目標與應用價值

本專案的核心價值在於利用 AI 提早識別出「即將爆發」的內容。

- **商業價值：** 協助媒體精準投放資源，提升運營效率。
- **社會價值 (應用)：** 建立一套『數位檢傷分類 (Digital Triage)』機制，作為查核中心的工具，將有限的查核人力優先部署在「高擴散預警」的內容上，實現源頭防禦。讓人類專家智慧能精準投放在最危險的 20% 資訊上，從而極大化社會防禦的韌性。

三、 系統架構與自動化監控

本專案採用 Stacking 集成法與多模態融合架構，達成從資料擷取到戰情預警的全自動化監控：

1. **全域蒐集引擎 (資料流)：** 背景自動蒐集台灣六大主流媒體新聞，包含 TVBS、ETtoday、SETN、UDN、EBC、CNA，突破手動複製貼上的效能瓶頸。原始資料經過清洗、特徵工程與探索性資料分析。
2. **本地資料庫：** 將新聞文本、發布時間、來源媒體等特徵，即時寫入系統資料庫。
3. **雙軌 AI 預測引擎 (模型層與決策層)：**
    - **模型層：** 包含中文語意 (MacBERT)、結構特徵 (Hybrid RoBERTa) 與情緒特徵 (Emotion Transfer Model)。
    - **決策層：** 資料入庫瞬間自動觸發 Wide & Deep 爆紅預測與假訊息交叉比對。採用 Stacking 堆疊法，以 GBDT 學習最佳權重組合，輸出最終預測。
4. **即時戰情室：** 前端介面無縫介接資料庫，可設定最快每 5 秒自動刷新面板資訊。

四、 關鍵技術一：資料工程 (Data Engineering)

- **資料時間跨度與規模：** 涵蓋 2025 年 11 月至今，總筆數達 23,000+ 筆新聞文本。
- **標籤定義 (Label)：** 依據新聞網站熱門新聞頁面與一般新聞頁面做標記。
- **克服資料不平衡 (Imbalance)：** 原始資料中，Viral News (熱門) 佔 20.0%，Normal News (一般) 佔 80.0%。熱門與一般約為 1:4，這反映了真實世界中爆紅新聞本就是少數的現實，也是後續模型訓練的挑戰。

五、 關鍵技術二：讀者情緒與風險量化

- **情緒資料來源：** 利用新聞平台 (如 UDN/Yahoo) 的使用者真實「心情投票 (Reactions)」數據 (按讚、生氣、難過等) 作為 Ground Truth。
- **風險權重設計：** 我們定義風險 (Risk) 不等於負面情緒。訓練 Emotion Transfer Model 讓模型學會什麼樣的文字會引發讀者的特定情緒。
  - **高風險情緒 (1.2x 權重)：** 憤怒 (Angry)、恐懼 (Fear)，最易導致社會對立與恐慌。
  - **中風險情緒 (1.2x 權重)：** 悲傷 (Sad)、驚訝 (Surprise)，可能為標題黨或聳動內容。
  - **低風險情緒 (0.8x 權重)：** 開心 (Happy)、溫馨 (Warm)，屬娛樂或正向內容，降低風險分。
- **風險分數計算 (Risk Scoring Formula)：** 最終的 Risk Score 是結合 Viral Score (Stacking 模型預測的基礎熱度機率，0-100) 與 Threat Weight (情緒危害權重，0.5-1.5) 的加權結果。
  - **數位檢傷分類機制 (Triage Criteria)：**
    - 🔴 **P0 紅色警戒 (Critical)：** Risk Score ≥ 80 (高熱度 + 高負面情緒)。建議優先查核，需立即介入，因該內容極易擴散且具煽動性。
    - 🟡 **P1 橘色觀察 (Warning)：** 50 ≤ Risk Score < 80 (中高熱度或情緒不明)。建議持續關注，監控觀察熱度，若情緒轉趨激烈則升級。
    - 🟢 **P2 綠色安全 (Safe)：** Risk Score < 50 (低熱度或正向情緒)。為常規資訊，自動歸檔，無需浪費查核資源。

六、 實驗成果與技術突破

1. 熱度預測主模型訓練：

- **顯著效能躍升：** 相較於基線模型 (XGBoost) 的 F1-Score 0.534，Stacking + Emotion 系統達到了 0.7456。這代表透過融合語意、結構、情緒等多模態特徵，系統預測能力提升了 40%，證明單一模型無法解決複雜的新聞熱度預測問題。
- **解決「狼來了」效應：** XGBoost 雖有 96.2% 召回率，但 Precision 僅 36.9% (誤報率極高)。Stacking 成功將準確率提升至 63.8%。這在實務上意味著為查核人員節省了近一半篩選無效資訊的時間。
- **高召回率 (High Recall)：** 在提升準確度的同時，Stacking 仍維持了 89.67% 的召回率。這符合數位檢傷「寧可適度誤判，絕不漏放」的核心原則。成功進入高準確與高召回的理想區域 (Target Zone)。

2. 讀者情緒辨識模型訓練：

- **深度學習的 SOTA 表現：** 最終採用的 RoBERTa-Large + Focal + FGM 模型，以 0.7703 的 F1-Score 奪冠。這關鍵在於提升對「隱晦情緒」(如反串、擔憂) 的捕捉能力。
- **精準捕捉風險情緒：** 針對高風險的「擔心 (Worried)」類型的 Precision 高達 88%，證明系統能精準識別最具社會危害性的恐慌內容。
- **傳統模型的韌性：** SVM 模型以 F1-Score 0.7552 位居第四，且訓練僅需 13.9 秒，展現極高 CP 值，是運算資源受限環境下的極佳替代方案。

七、 系統可信度與誤判探討

我們深知沒有 100% 完美的模型，系統定位是「寧可錯殺不漏放」的檢傷分類網。

- **模型履歷：** 訓練集包含 30,000+ 筆來自三立、udn、ettoday、自由、tvbs、中央社之數據。
- **誤判探討：**
  - **偽陽性 (False Positive) - 高分沒爆紅：** 原因多為標題農場但內文空洞。
  - **偽陰性 (False Negative) - 低分卻爆紅：** 原因包含非主流迷因發酵（AI 缺乏對應語境而無法辨別），或是冷門新聞意外被擁有龐大流量的網紅或公眾人物分享。

八、 開發方法與團隊協作

- **敏捷式開發 (Agile)：** 專案分為三階段衝刺。Sprint 1 (基建期) 建立框架與資料庫；Sprint 2 (模型期) 訓練熱度與情緒模型；Sprint 3 (整合期) 進行系統整合與介面設置。
- **工具與協作：** 採用 Trello 看板式追蹤，並進行每日 Stand-up Meeting 快速同步進度。
- **系統部署與環境：** 前端介面使用 Streamlit，語言框架為 Python 3.10 與 PyTorch 2.0 (包含 macOS MPS 加速)，並透過 Git 與 Streamlit Community Cloud 進行版控與部署。
- **AI 輔助開發：** 專案中約 70% 的程式碼生成、除錯優化 (如解決 macOS MPS 相容性) 與創意發想 (如構建 Streamlit CSS) 皆有賴於 Gemini 的協助。

九、 參考文獻

1. Vosoughi, S., Roy, D., & Aral, S. (2018). *The spread of true and false news online*. Science.
2. Berger, J., & Milkman, K. L. (2012). *What makes online content viral?* Journal of Marketing Research.
3. Ren, Y., & Yang, J. (2017). *Early Prediction of News Virality using Deep Learning*. Stanford University.
4. Cui, Y., et al. (2020). *Revisiting Pre-Trained Models for Chinese Natural Language Processing*. EMNLP.
5. Wu, S. H., et al. (2019). *Monpa: Multi-objective NER POS Annotator for Chinese*. ACM.
6. Lin, T. Y., et al. (2017). *Focal Loss for Dense Object Detection*. ICCV.

7. Wolf, T., et al. (2020). *Transformers: State-of-the-Art Natural Language Processing*. EMNLP.