Pre-Viral：基於語意優先集成學習與雙軌擴散驗證之新聞熱度早期預警框架

(Pre-Viral: An Early Warning Framework for News Virality Based on Semantics-First Stacking and Dual-Track Diffusion Validation)

摘要 (Abstract)

在數位新聞產業中，標題是決定流量轉化的「第一真理時刻」(The First Moment of Truth)。然而，在生成式 AI 導致資訊海嘯的時代，假新聞傳播速度已達真實新聞的 6 倍。本研究旨在解決現有熱度預測模型面臨的資料異質性、類別不平衡，以及**過度依賴單一語意導致的混淆訊息誤判**等問題。

本研究實作了從資料獲取到模型部署的「全自動化零人工介入」完整流程：在資料工程端，開發了具備 Anti-Zombie 機制的全域爬蟲，並徹底解決前後端解耦與記憶體崩潰問題，首創「語意優先資料救援」機制。在核心演算法端，我們嚴格執行了多階段演進實驗，不僅提出 F1-Score 達 0.746 的 Semantics-First Stacking 終極架構，更於複賽階段**導入「環境脈絡特徵 (Contextual Features)」與首創的「雙軌交互驗證機制 (Dual-Track Validation)」**。結合 AI 熱度預測與外部跨媒擴散查證，本系統成功建構數位檢傷機制，將查核防線推進至 $T=0$ 時刻，不僅能精準捕捉爆紅黑天鵝，更能主動攔截高煽動性的烏龍爆料與農場文。

第一章 緒論 (Introduction)

1.1 產業痛點

根據林照真 (2012) 對數位新聞產業的觀察，以及本專案前期的實務探索，我們界定出四大痛點：

1. **被動接收與手動瓶頸**：編輯台依賴 GA (Google Analytics) 等事後數據，無法在新聞發布當下 ($T=0$) 預判潛力。傳統工具多需手動輸入分析，效能低落，無法應對實務龐大資訊量。
2. **資訊過載**：每日數千則新聞中，真正具備「病毒式擴散 (Viral)」潛力的不到 5%。
3. **缺乏環境脈絡**：傳統預測多依賴純文字語意，忽略了發布時機與結構誘餌對社群演算法的決定性影響，導致深夜冷門新聞常因情緒強烈被誤判。
4. **防禦缺口與混淆訊息誤導**：高熱度內容常伴隨假訊息風險。若單靠語意模型，極易被標題聳動但無人跟進的「農場文或烏龍爆料」欺騙，缺乏多方比對的自動預警機制。

1.2 研究目標

本計畫旨在建構一套「新聞熱度早期預警系統」，具體實作目標為：

1. **全自動化監控**：建立 24H 穩定、抗斷網且前後端解耦的即時資料搜集與渲染管道。
2. **語意在地化與特徵融合**：克服通用模型對台灣網路用語的理解隔閡，並結合情緒喚醒度、時間脈絡與結構誘餌，降低偽陽性誤判。
3. **模型最佳化與雙軌防禦**：在「不漏抓熱點 (High Recall)」的前提下提升精確度，並透過「熱度預測模型」與「擴散查證模型」交互比對，精準攔截混淆訊息。

第二章 文獻探討 (Literature Review)

本章節探討支撐本研究的核心理論支柱：新聞價值理論、中文自然語言處理模型、類

別不平衡學習策略，以及環境脈絡特徵。

2.1 新聞價值與數位轉型 (News Values & Digital Transformation)

Galtung & Ruge (1965) 的新聞價值理論奠定了新聞學基礎，指出負面性 (Negativity) 與突發性 (Unambiguity) 是新聞受到關注的主因。李竹君 (2016) 的研究進一步指出，在數位媒體語境中，「即時性」與「短時間爆發力」是衡量熱度的關鍵指標。

Berger & Milkman (2012) 則從心理學角度提出「情緒喚醒度 (Emotional Arousal)」理論，證實高喚醒情緒 (如憤怒 Arousal、焦慮 Anxiety) 是驅動內容病毒式分享 (Viral Sharing) 的核心動力，而低喚醒情緒 (如悲傷) 則會抑制分享。本研究據此將「讀者情緒」列為模型的一級特徵，並特別關注「憤怒」與「擔心」這類高喚醒情緒。

2.2 頭條定義與標籤策略 (Labeling Strategy)

柯裕嘉 (2011) 定義「頭條」為經守門人篩選、具備顯著版位的新聞。然而本研究在實務資料探勘中發現，若依據傳統版位定義 L2 (絕對頭條)、L1 (焦點新聞)、L0 (一般新聞)，L2 樣本極度稀缺 (每日僅 1-2 則)，將導致模型難以收斂。因此，本研究採納二元分類 (Binary Classification) 策略，將 L1 與 L2 合併為 Label 1 (熱門)，L0 為 Label 0 (一般)，此修正解決了類別極端不平衡的問題，使模型訓練具備可行性。

2.3 中文語意處理與預訓練模型 (Chinese PLMs)

Wu (2023) 強調深度學習在中文斷詞的優勢。在預訓練語言模型選型上，Cui et al. (2020) 證實 MacBERT (Whole Word Masking) 在中文語意理解上優於 Google BERT。MacBERT 透過「相似詞替換」而非「[MASK] 標記」來進行預訓練，縮小了預訓練與微調階段的差異 (Pre-training/Fine-tuning Discrepancy)。本研究選用中研院 Monpa 系統進行斷詞，並以 MacBERT 作為核心語意特徵提取器，以克服多語言模型 (如 XLM-R) 對台灣在地用語理解不足的問題。

2.4 類別不平衡學習：Focal Loss 與集成學習

針對熱門新聞僅佔少數的長尾分佈問題，Lin et al. (2017) 提出的 Focal Loss 透過修改交叉熵損失函數，降低易分類樣本的權重，公式為 $FL(p_t) = -\alpha_t (1-p_t)^\gamma \log(p_t)$。此外，Wolpert (1992) 提出的 Stacking (Stacked Generalization) 能有效融合不同性質模型的優勢。本研究結合此二者，以 Focal Loss 優化基底模型召回率，再以 Stacking 提升最終預測精確度。

2.5 環境脈絡與結構誘餌之預測價值 (Contextual & Structural Features)

除了情緒與語意，資訊擴散理論亦強調「環境脈絡」的重要性。Ren & Yang (2017) 針對社群網路擴散的研究指出，發布時機 (天時) 對早期熱度預測具有高度權重。因此，本研究導入 is_prime_time (黃金時段) 與發酵延遲時間特徵，使模型具備判斷時間脈絡的能力。

此外，針對農場文與假訊息的氾濫，Chakraborty et al. (2016) 的點擊誘餌偵測研究證實，刻意打破認知慣性的結構 (如特定長度、過高的驚嘆號/問號密度、數字標籤) 是吸引點擊的強烈特徵。本研究將此結構特徵納入預測與假訊息驗證模型中，以強化系統對混淆訊息的辨識力。

第三章 系統架構與資料工程 (System Architecture)

3.1 爬蟲技術演進與底層防禦 (Crawling & System Resilience)

本專案的系統工程經歷了四次重大迭代：

- **V1.0 靜態爬蟲**：使用 requests，因無法處理 AJAX 動態加載而失敗，資料遺失率 80%。
- **V5.0 動態爬蟲**：引入 Selenium，成功模擬滾動，但在長時間運行後遭遇 Chrome 記憶體洩漏問題。
- **V12.0 抗殭屍爬蟲**：實作 Process Management Daemon。系統即時監控 chromedriver 的 CPU 與記憶體狀態，一旦偵測到僵屍進程 (Zombie Process) 或記憶體溢出 (>2GB)，立即強制回收並重啟 Session。
- **V15.0 (複賽終極版) 全自動化與底層解耦**：為達成「零人工介入」的戰情室展示，我們實作了前後端解耦架構。爬蟲腳本改用 Selenium 原生 Service 管理徹底解決驅動衝突，並將爬蟲輸出「靜音 (DEVNULL)」導向背景執行。同時，針對 Mac (Apple Silicon) 晶片運行 AI 模型時易導致的 Segmentation fault，系統強制寫入環境變數（關閉 Tokenizer 與 PyTorch 多執行緒），徹底根除了高併發下的記憶體崩潰，達成企業級的穩定度。

3.2 資料救援機制 (Data Rescue)

針對 45% 資料缺乏時間戳記的問題，實作「語意優先集成 (Semantics-First Stacking)」。拒絕刪除資料，利用 Level-0 模型 (XGBoost) 的 Native NaN Support，在缺失結構特徵時強迫模型學習 MacBERT 提取的「純語意」特徵，最大化資料利用率。

3.3 全自動戰情資料流 (Automated Data Pipeline)

捨棄手動輸入，系統現採用 Pipeline 架構：自動爬蟲模組於背景巡邏六大媒體 $\rightarrow$ 新聞文本與時間脈絡即時寫入本地關聯式資料庫 (News_Data.csv) $\rightarrow$ Streamlit 戰情室介面設定 Watchdog，每 10 秒自動拉取最新資料庫內容並觸發 AI 預測。全程資料不落地，達成真正意義上的即時數位檢傷。

第四章 實驗設計與流程詳述 (Experimental Design & Process)

本章節詳細描述從特徵工程到模型迭代的完整操作流程，還原每一次技術決策的脈絡。

4.1 實驗環境與資料集配置

- **資料來源**：蒐集自台灣主流新聞媒體網站。
- **資料量**：23,000+ 筆新聞數據。
- **標籤定義**：整合 Google News 熱榜 (11-17_googlenews_scraper) 與社群指標，定義 Label 1 (Viral) 與 Label 0 (Non-Viral)。
- **評估指標**：F1-Score, Precision, Recall, Accuracy。

4.2 輔助任務：在地化讀者情緒識別訓練流程 (Emotion Radar)

此任務目標是訓練一個能準確判讀標題隱含情緒（如：Angry, Worried, Happy）的模型，作為下游熱度預測的關鍵特徵。

1. **基準線建立 (Baselining)**：使用 TF-IDF (5000 維) 結合 Monpa 斷詞進行特徵提取，投入 7 種傳統機器學習模型進行訓練。發現 Linear SVM 以 Accuracy 0.7181 奪冠，證明在高維稀疏特徵下，SVM 仍具備極佳的魯棒性。
2. **深度學習引入 (Deep Learning)**：引入 BERT 家族模型 (BERT-wwm, RoBERTa-wwm-ext)。發現 Base 版模型的 F1-Score (約 0.748) 並未顯著超越 SVM (0.755)，推測因新聞標題極短，上下文資訊有限。
3. **SOTA 優化 (Optimization)**：升級至 RoBERTa-Large 模型。針對樣本數較少

的負面情緒 (如 Worried)，引入 Focal Loss ($\gamma=2.0$)。加入 FGM (Fast Gradient Method) 進行對抗訓練，在 Embedding 層增加擾動，提升模型對抗惡意標題的抗性。最終 F1-Score 突破至 0.7703。

4.3 核心任務：熱度預測模型四階段演進與雙軌擴展 (Virality Prediction)

Phase 1: 傳統模型競技 (Benchmark)

- 流程：提取結構特徵與 TF-IDF，訓練 XGBoost、RF 等模型。
- 結果：XGBoost 的 Recall 高達 0.9696，但 Precision 僅 0.3681。模型傾向將所有新聞都猜成熱門 (Over-Prediction)，導致嚴重的「狼來了」效應。

Phase 2: BERT 模型選型 (Model Selection)

- 流程：評測 Facebook XLM-RoBERTa (多語言)、Chinese-RoBERTa (通用中文) 與 MacBERT (全詞遮罩)。
- 結果：MacBERT-Base (F1: 0.532) 雖然 F1 與其他模型持平，但其 Accuracy (0.689) 與 Precision (0.561) 皆為最高，證明其 WWM 機制更適合捕捉「標題黨」特徵，獲選為基底模型。

Phase 3: 進階策略優化 (Strategy Evolution)

- 策略 A (Hybrid RoBERTa)：拼接語意向量與結構特徵。結果 F1: 0.619，缺乏彈性。
- 策略 B (Self-Training The Trap)：利用 Teacher 模型篩選高信心樣本進行半監督學習。結果 Accuracy 飆升至 0.9558，但 Recall 重挫至 0.40。模型過濾掉了所有「黑天鵝事件」，喪失預警價值。
- 策略 C (Focal Loss + Full Data)：放棄篩選數據，改用 Focal Loss ($\gamma=2.0$) 強迫模型關注難分類樣本。成功將 Recall 救回至 0.859，F1 提升至 0.646。

Phase 4: 終極架構 - Context-Aware Semantics-First Stacking

- 流程：在原有的 Level-0 基底模型 (MacBERT 語意深、RoBERTa-Emotion 情緒廣、XGBoost 結構快) 中，額外對齊了時間脈絡 (黃金時段) 與結構誘餌特徵。Level-1 使用 Logistic Regression 學習最佳權重組合。
- 結果：F1-Score 0.746，Precision 0.638，Recall 0.897。加入環境特徵後，模型學會了「看場合」，大幅降低了深夜冷門新聞被誤判的偽陽性。

Phase 5: 雙軌交互驗證機制 (Dual-Track Validation) [複賽新增]

為回應評審對於「單篇語意易受複雜假訊息欺騙」的質疑，系統引入兩大外部驗證模組：

1. **TrendValidator (擴散動能驗證)**：透過 Google Search API 進行跨媒體共識比對。
2. **FakeNewsDetector (農場文防護網)**：利用啟發式特徵計算假訊息機率。

此雙軌機制與 Stacking 模型並行運作，構成了本系統最堅固的防線。

第五章 實驗結果全景評測 (Comprehensive Experiments)

5.1 讀者情緒識別：22 種模型完整評測表

排名	模型架構 (Model)	類別	F1-Score	Precision	Recall	訓練時間 (s)	備註
1	RoBERTa-Large + FGM	DL (Large)	0.7703	0.7709	0.7704	29,219	SOTA 冠軍
2	MacBERT-Large-Ensemble	DL (Large)	0.7683	0.7692	0.7682	3,738	
3	Triple-Large Ensemble	Ensemble	0.7566	0.7581	0.7579	-	
4	Linear SVM	Traditional	0.7552	0.7572	0.7582	13.9	CP 值之王
5	RoBERTa-wwm-ext	DL (Base)	0.7488	0.7476	0.7488	4,578	
6	MacBERT-Base	DL (Base)	0.7475	0.7482	0.7469	4,420	
7	CKIP-BERT-base	DL (Base)	0.7293	0.7311	0.7303	549	中研院模型
8	BERT-wwm	DL (Base)	0.7217	0.7221	0.7241	551	
9	XLNet-Base	DL (Base)	0.7150	0.7180	0.7120	5,100	
10	Linear SVM (TF-IDF)	Traditional	0.7181	0.7200	0.7150	12.5	基準線
11	DistilBERT	DL (Light)	0.7020	0.7050	0.6980	2,300	

12	XGBoost (Basic)	Traditional	0.6783	0.6850	0.6720	25.6	
13	LightGBM	Traditional	0.6743	0.6800	0.6690	15.4	
14	Logistic Regression	Traditional	0.6652	0.6700	0.6600	8.2	
15	Naive Bayes	Traditional	0.6339	0.6400	0.6280	0.5	假設獨立性導致失效
16	KNN (k=5)	Traditional	0.6165	0.6254	0.6209	0.01	
17	Random Forest	Traditional	0.5051	0.5100	0.5000	18.2	稀疏特徵表現差
18	Decision Tree	Traditional	0.3884	0.3900	0.3800	2.1	過度擬合
19	ChineseBERT-base	DL (Base)	0.3100	0.2751	0.4448	425	訓練失敗
20	ALBERT-tiny	DL (Light)	0.2500	0.2400	0.2600	300	
21	Dummy (Most Frequent)	Baseline	0.1800	0.0000	1.0000	0.0	
22	Dummy (Stratified)	Baseline	0.1800	0.1800	0.1800	0.0	

5.2 熱度預測：演進全歷程數據表 (Full Evolution)

階段 (Phase)	模型策略 (Model Strategy)	Precision	Recall	F1-Score	Accuracy	實驗結論

Phase 4	**Stacking (Final)**	**0.6382**	**0.8967**	**0.7456**	**0.7420**	**最佳平衡。解決所有痛點。**
Phase 3	Focal Loss + Full Data	0.5173	0.8587	0.6457	0.6308	最佳單體策略，召回率救回。
Phase 3	Hybrid RoBERTa	0.4886	0.8460	0.6194	0.6371	結構特徵有效，不如 Focal Loss 穩健。
Phase 4	Dual-BERT Stacking	0.4848	0.6884	0.5689	0.6358	雙 BERT 集成，效果不如預期。
Phase 2	Chinese-RoBERTa	0.5485	0.5301	0.5392	0.6836	表現優於 XLM，但不及 MacBERT。
Phase 1	XGBoost	0.3694	0.9620	0.5339	0.4082	極端召回。誤報率過高，無法實用。
Phase 2	MacBERT-Base	0.5614	0.5064	0.5325	0.6895	語意理解最強，選為基底。
Phase 1	Logistic Regression	0.4901	0.5752	0.5293	0.6428	
Phase 1	LightGBM	0.4984	0.5606	0.5276	0.6496	
Phase 3	Self-Training	0.7742	0.4000	0.5275	0.9558	失敗 (Trap)。過度保守，喪失預警價值。

Phase 1	Linear SVM	0.4774	0.5855	0.5260	0.6315	
Phase 1	Random Forest	0.5358	0.4778	0.5051	0.6732	
Phase 2	XLM-RoBERTa	0.5601	0.4029	0.4687	0.6408	多語言模型對在地語境適應不良。
Phase 1	Decision Tree	0.4362	0.4121	0.4238	0.6088	過度擬合。
Phase 1	Naive Bayes	0.4668	0.2094	0.2891	0.6405	完全不適合語意分析。

第六章 應用場景與社會影響力 (Impact)

6.1 雙軌數位檢傷預警機制 (Dual-Track Digital Triage)

結合 AI 內在潛力預測與全網外部擴散動能，本系統的風險預警燈號全面升級：

- 🔥 **P0 紅色警戒 (Critical Priority)**：AI 預測極高熱度，且外部具備高度擴散動能。系統判定為真實爆紅事件，建議媒體優先推播。
- ⚠️ **P1 黃色觀察 (Observation)**：AI 預測具備中度爆紅潛力。系統自動持續監控後續發酵路徑。
- 🟢 **P2 綠色安全 (Safe / Routine)**：無明顯爆紅與混淆風險，系統自動過濾，節省人力。
- 🚨 **混淆訊息預警 (Confusing Message Alert) [複賽首創]：當 AI 判定極具爆紅潛力（標題極度煽動），但 TrendValidator 查無其他媒體跟進，或 FakeNewsDetector 給出高假新聞機率時觸發。** 系統將強勢攔截，精準抓出企圖帶風向的農場文與獨家烏龍爆料，建議查核單位立即啟動人工查核。

6.2 商業與社會價值

- **商業端**：「AI 總編輯」輔助決策。在點閱率為零的發布首小時，即透過文字基因抓出潛力股，最大化長尾效應。
- **社會端**：建立「寧可錯殺不願漏放」的防禦體系。不依賴單一黑盒子，透過雙軌比對有效收斂誤報，解決「資訊過載」問題，讓人類查核人員能專注於真正具備高殺傷力的 Top 5% 混淆資訊上。

第七章 結論 (Conclusion)

本專案 Pre-Viral 透過完整的技術迭代，證明了「資料決策 (Data-Centric AI)」與「系統工程架構」的關鍵價值。從解決 Chrome 記憶體洩漏與 Mac 底層衝突的全自動化監控網，到從 Self-Training 失敗中轉向 Focal Loss 與 Context-Aware Stacking 的演進，再到最終首創的「雙軌擴散驗證機制」。本系統不僅解決了預測準確率的學術挑戰，具備 89.7% 的高召回率，更透過直觀的紅綠燈數位檢傷介面，為數位時代的資訊過載與假新聞防禦，提供了一套高度成熟、具備實務落地價值的解決方案。

第八章 參考文獻 (References)

1. Galtung, J., & Ruge, M. H. (1965). The Structure of Foreign News. *Journal of Peace Research*, 2(1), 64-91.
2. Ko, Y.-C. (柯裕嘉) (2011). A Study on Newspaper Consumers' Preferences for Form and Content of Front-page News. *National Taiwan Normal University*.
3. Lee, C.-C. (李竹君) (2016). Rethinking News Values: The Case of Real-Time News. *National Taiwan University*.
4. Lin, C.-C. (林照真) (2012). Correlation between Digital Journalism and Development of Digital News Industry. *NSC Report*.
5. Vosoughi, S., Roy, D., & Aral, S. (2018). The spread of true and false news online. *Science*, 359(6380), 1146-1151.
6. Berger, J., & Milkman, K. L. (2012). What makes online content viral? *Journal of Marketing Research*, 49(2), 192-205.
7. Wu, T.-H. (2023). Research On Chinese Word Segmentation with Deep Neural Network. *NTUST*.
8. Cui, Y., Che, W., Liu, T., Qin, B., & Yang, Z. (2020). Revisiting Pre-Trained Models for Chinese Natural Language Processing. *Findings of EMNLP 2020*.
9. Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *ICCV 2017*.
10. Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, 5(2), 241-259.
11. Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., ... & Stoyanov, V. (2019). RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv preprint arXiv:1907.11692*.
12. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *NAACL 2019*.
13. ROCLING 2025 Submission 52. (2025). A Fake News Detection Model Utilizing Graph Neural Networks.
14. Ren, Y., & Yang, J. (2017). Early Prediction of News Virality using Deep Learning. *CS224N Project Report, Stanford University*.
15. Chakraborty, A., Paranjape, B., Kakarla, S., & Ganguly, N. (2016). Stop Clickbait: Detecting and Preventing Clickbaits in Online News Media. *Advances in Social Networks Analysis and Mining (ASONAM)*.